


Analisis Big Data GitHub dan Stack Overflow untuk Prediksi Tren Teknologi serta Rekomendasi Personal Learning Path bagi Pengembang Perangkat Lunak

R. Syailindra Alfarraiel / 24083010030 / Sains Data / Big Data D

Perkembangan teknologi perangkat lunak berlangsung sangat cepat. Setiap tahun, berbagai macam bahasa pemrograman, framework, dan library baru bermunculan, sementara sebagian yang lain mulai ditinggalkan. Bagi programmer, terutama yang masih awam dan baru terjun, tantangan terbesar bukan hanya memahami dasar kode, tetapi memutuskan skill apa yang paling relevan untuk dipelajari agar tidak ketinggalan zaman dan tetap kompetitif di pasar kerja. Di sinilah GitHub dan Stack Overflow berperan penting. GitHub adalah platform komputasi dengan lebih dari 200 juta repositori dan 28 juta pengguna. Stack Overflow adalah platform pusat tanya jawab khusus pemrograman terbesar di dunia dengan lebih dari 23 juta pertanyaan dan 50 juta jawaban. Kedua platform ini secara kolektif membantu ekosistem big data yang merekam perilaku, minat dan pergerakan komunitas developer secara real-time. Berikut ini adalah skema alur data dari Github dan Stack Overflow hingga menghasilkan rekomendasi skill:



Gambar 1.0 Flowchart ekosistem big data GitHub dan Stack Overflow

Untuk memahami karakteristik big data pada studi kasus ini, berikut adalah tiga aspek yang akan di analisis: Volume, Velocity, dan, Variety. Volume mengacu pada seberapa besar ukuran data yang dihasilkan. Pada GitHub, terdapat lebih dari 200 juta repositori. Jika setiap repositori memiliki rata rata ukuran sebesar 10 MB, maka total data yang tersimpan mencapai 2 petabyte, Sementara itu, Stack Overflow memiliki lebih dari 50 juta jawaban. Jika rata rata berisi 500 karakter teks, total teks mencapai sebesar 25 miliar karakter. Hal ini menunjukkan bahwa skala sebesar ini tidak mungkin dianalisis menggunakan spreadsheet biasa. Dibutuhkan kerangka big data seperti Apache Hadoop atau Apache Spark untuk memprosesnya.

Selanjutnya adalah velocity. Velocity mengukur seberapa cepat data baru dihasilkan. Setiap hari, tercatat sekitar 10.000 pertanyaan baru di Stack Overflow dan 50.000 repositori baru di GitHub. Selain itu, aktivitas seperti commit, push, dan pemberian stars terjadi setiap detik. Untuk prediksi tren teknologi, data perlu dianalisis dalam rentang mingguan atau bahkan harian, agar dapat mendeteksi lonjakan minat terhadap suatu teknologi secara dini. Terakhir yaitu Variety. Variety mengacu pada keragaman format data yang harus diolah secara bersamaan dalam ekosistem ini. Terdapat tiga jenis data utama: data teks (judul pertanyaan, jawaban, komentar, deskripsi repositori), data kode (source code dalam berbagai bahasa pemrograman), serta data terstruktur berupa metadata seperti timestamp, jumlah stars, tag teknologi, dan reputasi pengguna. Ketiga jenis data yang sangat berbeda ini harus diproses secara terintegrasi misalnya menggabungkan peningkatan jumlah stars, lonjakan pertanyaan, dan banyaknya repositori baru untuk menentukan apakah suatu teknologi sedang naik daun.

Sebagai Ilustrasi yang konkret, bayangkan kita ingin mengetahui apakah Svelte (Framework dan compiler JavaScript inovatif untuk membangun antarmuka web / UI) sedang menjadi tren. Dengan menggunakan data dari GitHub dan juga Stack Overflow, kita dapat mengetahui beberapa indikator untuk menganalisis hal tersebut. Misalnya dengan menggunakan indikator pertumbuhan stats per minggu, jumlah pertanyaan baru perhari, rasio upvote dan downvote jawaban, serta jumlah repositori baru yang menggunakan Framework Svelte. Jika ketiga metrik pertama mengalami peningkatan yang konsisten selama 3-6 bulan, maka Svelte layak direkomendasikan sebagai skill yang harus dipelajari. Dengan pendekatan yang sama, dapat dibangun sistem rekomendasi personal. Jika seorang programmer sering menggunakan React di GitHub dan sering bertanya tentang state management di Stack Overflow, sistem dapat merekomendasikan [Next.js](#) atau Redux Toolkit sebagai langkah berikutnya.

Saat ini, belum ada sistem terintegrasi yang melakukan prediksi tren secara real-time. Laporan yang tersedia bersifat tahunan (GitHub Octoverse, Stack Overflow Survey) sehingga tertinggal dari perubahan cepat di industri. Tantangan lain meliputi bias geografis (dominasi pengguna Barat), kualitas data (jawaban salah, stars yang dibeli), serta kesenjangan dengan pasar kerja

Agar ekosistem big data GitHub dan Stack Overflow dapat memberikan manfaat lebih besar, diusulkan tiga solusi:

1. Membangun dashboard publik real-time yang menampilkan "Trending Technologies Index" diperbarui setiap minggu.
2. Mengembangkan personal learning path recommendation engine berdasarkan riwayat aktivitas pengguna.
3. Integrasi dengan platform lowongan kerja (LinkedIn, JobStreet) agar rekomendasi skill sesuai permintaan pasar.

Berdasarkan pembahasan di atas, dapat disimpulkan bahwa GitHub dan Stack Overflow menyimpan big data yang sangat berharga untuk memahami dinamika dunia pemrograman. Dari sisi Volume, kedua platform ini menghasilkan data dalam skala petabyte yang tidak mungkin dianalisis secara manual. Dari sisi Velocity, laju pertumbuhan data yang mencapai puluhan ribu repositori dan pertanyaan baru setiap hari menuntut adanya sistem pemrosesan real-time. Dari sisi Variety, keragaman jenis data mulai dari teks, kode, hingga metadata memerlukan teknik pemrosesan yang terintegrasi. Studi kasus yang diilustrasikan dengan framework Svelte menunjukkan bahwa prediksi tren teknologi sangat mungkin dilakukan dengan menggabungkan metrik seperti pertumbuhan stars, jumlah pertanyaan baru, dan rasio upvote. Namun demikian, sistem yang ideal saat ini belum tersedia karena masih adanya tantangan seperti bias geografis, kualitas data yang kurang terjaga, serta kesenjangan antara popularitas di komunitas dan kebutuhan pasar kerja nyata.

Oleh karena itu, diusulkan tiga solusi ke depan agar ekosistem big data ini lebih bermanfaat, terutama bagi programmer junior dan pencari kerja di bidang teknologi. Pertama, dashboard publik real-time yang menampilkan indeks tren teknologi secara mingguan. Kedua, mesin rekomendasi personal learning path yang disesuaikan dengan riwayat aktivitas pengguna di kedua platform. Ketiga, integrasi dengan platform lowongan kerja agar rekomendasi skill tidak hanya populer di komunitas tetapi juga benar-benar dibutuhkan oleh industri. Dengan implementasi ketiga solusi tersebut, ekosistem big data GitHub dan Stack Overflow dapat menjadi panduan belajar yang jauh lebih akurat, relevan, dan bermanfaat bagi programmer di seluruh dunia, termasuk di Indonesia.

